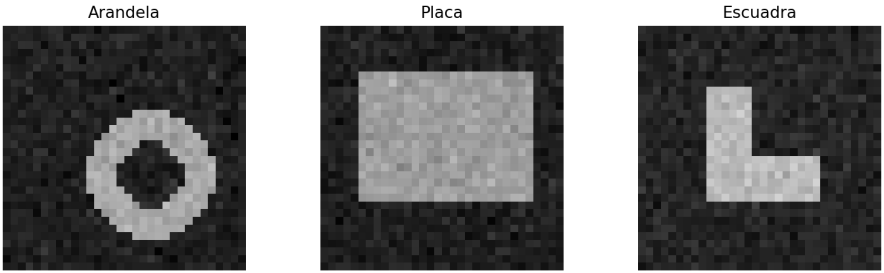
Aprender a clasificar imágenes

Visión artificial para producto y fabricación aditiva

Fundamentos de la Inteligencia Artificial

Tema 2 · Sesión de 150 minutos

De los píxeles a una decisión



¿Podemos aprender a distinguir estas tres familias sin escribir una regla para cada dibujo?

Objetivos de la sesión

- Distinguir datos, etiquetas y parámetros aprendidos.
- Separar entrenamiento, validación y prueba sin compartir piezas.
- Comparar una referencia, un modelo lineal y una red pequeña.
- Interpretar errores y reconocer límites de generalización.

Ruta · 150 minutos

Bloque	Minutos
Problema y datos · actividad 1	20
Separación · actividad 2	20
Referencia · actividad 3	20
Descanso	10
Redes y CNN · actividad 4	30
Evaluación · actividad 5	20
Cambio de condiciones · actividad 6	20
Cierre	10

Clasificación: una etiqueta por imagen

- Entrada: una imagen preparada de forma consistente.
- Salida: una clase entre las definidas para el problema.
- Hoy: arandela, placa o escuadra en dibujos sintéticos.
- La clasificación no indica dónde está el objeto ni dibuja su contorno.

Aprendizaje supervisado

Durante entrenamiento

Imágenes + etiquetas $\rightarrow$ ajuste de pesos $\rightarrow$ modelo

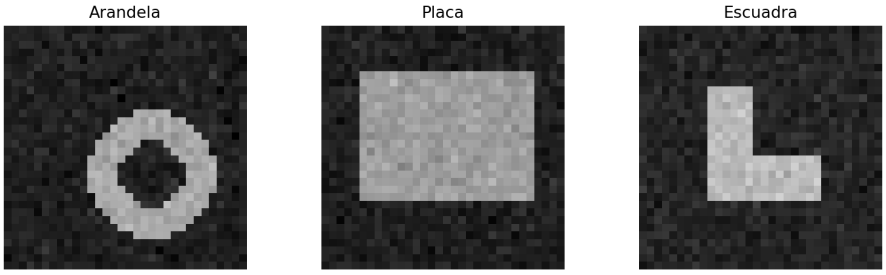
Durante inferencia

Nueva imagen $\rightarrow$ modelo con pesos fijados $\rightarrow$ predicción

Las etiquetas definen el problema

- ¿Las clases son claras y excluyentes en esta tarea?
- ¿Qué ocurre si la imagen contiene dos piezas o ninguna?
- Una etiqueta incorrecta enseña una asociación incorrecta.
- El modelo no conoce automáticamente clases que no se incluyeron.

Datos del notebook: 540 imágenes



180 piezas sintéticas, tres capturas por pieza. Variamos tamaño, posición, iluminación y ruido. No son fotografías industriales.

Notebook · Actividad 1 · Explorar los datos

Predice → ejecuta → modifica → explica

Identifica qué cambios mantienen la clase. Consulta la forma de las imágenes y el identificador de pieza.

¿Tres capturas de la misma pieza son tres ejemplos independientes?
Tiempo: 10 minutos.

Tres conjuntos, tres funciones

Entrenamiento

Aprender pesos y ajustar el escalado.

Validación

Comparar modelos y elegir hiperparámetros.

Prueba

Estimar el resultado final tras cerrar las decisiones.

La fuga de información

- Capturas casi iguales de una pieza en conjuntos distintos facilitan la evaluación.
- Compartir lotes, pacientes o secuencias también puede crear dependencia.
- Separar según la unidad que deba ser nueva al desplegar.
- No ajustar el escalado con validación o prueba.

Separar por pieza

Entrenamiento	Validación	Prueba
108 piezas	36 piezas	36 piezas

Cada pieza y sus tres capturas pertenecen a un único conjunto. Comprobar también el reparto por clase.

Predice → ejecuta → modifica → explica

Ejecuta la separación por grupos y comprueba los recuentos.

¿Qué error cometeríamos separando capturas al azar?
Tiempo: 10 minutos.

Necesitamos una referencia

- Un acierto alto puede ser engañoso si una clase domina.
- Comparar con predecir siempre la clase más frecuente.
- Después usar un modelo sencillo que aprenda de los píxeles.
- Más complejidad solo se justifica si mejora lo que necesitamos.

Clasificador lineal: pesos sobre los píxeles

Puntuación de una clase

$$s_k = w_{k1}x_1 + w_{k2}x_2 + \cdots + b_k$$

- Cada píxel aporta a una puntuación.
- Aprender significa ajustar pesos con ejemplos etiquetados.
- La regresión logística transforma puntuaciones para comparar clases.

Preparar sin contaminar la evaluación

- Aplanar 32×32 genera 1024 valores por imagen.
- Estandarizar aprende medias y escalas en entrenamiento.
- Aplicar la misma transformación a validación y prueba.
- El pipeline mantiene unidas preparación y predicción.

Parámetros e hiperparámetros

- Pesos: se aprenden durante el ajuste del modelo.
- Regularización, número de neuronas y epochs: decisiones del entrenamiento.
- Comparar esas decisiones en validación.
- Consultar prueba repetidamente la convierte en parte del proceso de selección.

Notebook · Actividad 3 · Comparar referencias

Predice → ejecuta → modifica → explica

Compara mayoría y regresión logística. Prueba dos valores de regularización.
Registra el acierto en validación; conserva prueba cerrada.
Tiempo: 12 minutos.

Descanso · 10 minutos

Al volver: ¿qué añade una red neuronal al modelo lineal?

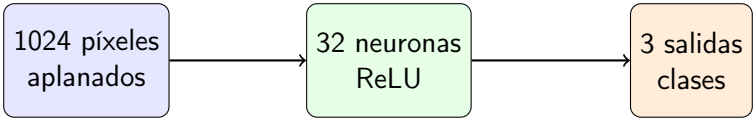
Una neurona: combinar y transformar

Idea

$$z = w_1 x_1 + \cdots + w_n x_n + b \qquad a = \max(0, z)$$

- La combinación ponderada resume entradas.
- Una función no lineal permite construir relaciones más complejas.
- No hace falta derivar estas expresiones para interpretar el experimento.

La red densa del notebook



Entrenamos una MLP pequeña. No comparte pesos espaciales como una CNN.

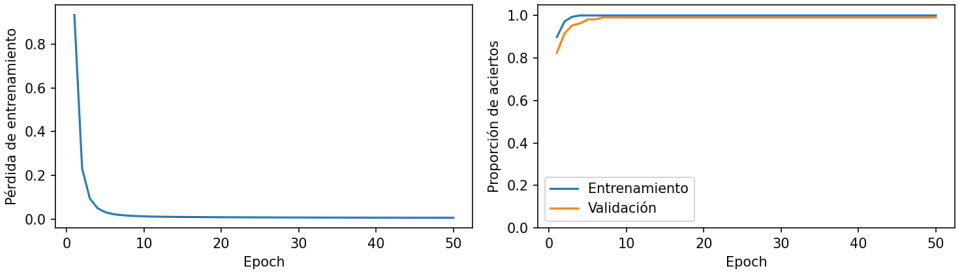
Cómo aprende: un ciclo repetido

- Predecir las clases de un lote de imágenes.
- Medir el desacuerdo con sus etiquetas mediante una pérdida.
- Calcular cómo cambiar los pesos para reducir esa pérdida.
- Actualizar los pesos y repetir. Un epoch recorre entrenamiento.

Pérdida y acierto no son lo mismo

- El acierto cuenta predicciones correctas.
- La pérdida también cambia con la puntuación asignada a las clases.
- Puede bajar la pérdida sin cambiar la clase predicha.
- Las curvas de validación se observan sin ajustar pesos con sus etiquetas.

Curvas del experimento



Una separación creciente puede indicar sobreajuste. Estas curvas concretas no garantizan utilidad fuera de los datos sintéticos.

Sobreajuste y generalización

- Memorizar detalles del entrenamiento puede perjudicar ejemplos nuevos.
- Más datos representativos y regularización pueden ayudar.
- El conjunto de validación debe representar el uso esperado.
- Un buen resultado en datos sencillos no demuestra robustez.

CNN: aprovechar vecinos y compartir filtros

Convolución

Un pequeño filtro recorre la imagen y reutiliza los mismos pesos en distintas posiciones.

- Las primeras capas pueden responder a patrones locales.
- Capas posteriores combinan esas respuestas.
- Pooling y reducción espacial resumen información.
- Compartir filtros no garantiza invariancia ante cualquier transformación.

CNN frente a red densa

- Densa del notebook: cada posición entra como una variable distinta.
- CNN: conserva organización espacial y comparte filtros.
- Ambas ajustan pesos a partir de una función de pérdida.
- Elegir arquitectura no sustituye separar bien los datos y evaluar errores.

Transferencia: reutilizar lo aprendido

Esquema

Imagen $\rightarrow$ extractor preentrenado $\rightarrow$ características $\rightarrow$ nueva cabeza de clasificación

- Congelar extractor: entrenar inicialmente la cabeza nueva.
- Ajuste fino: actualizar después parte del extractor con cuidado.
- Usar exactamente la preparación de entrada indicada por el modelo.
- La utilidad depende de la relación entre datos de origen y nuestra tarea.

Qué ejecutamos hoy y qué queda para ampliar

- Hoy entrenamos desde cero una regresión logística y una MLP pequeña.
- Las CNN y la transferencia se estudian aquí mediante esquemas.
- El notebook no descarga modelos preentrenados ni necesita GPU.
- Una extensión con fotografías requerirá datos documentados y validación propia.

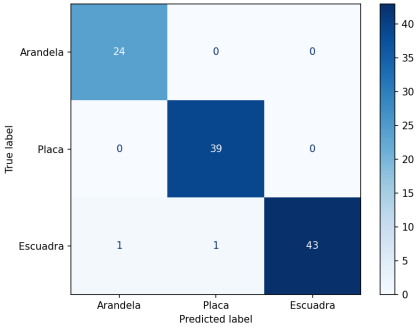
Predice → ejecuta → modifica → explica

Observa 50 epochs y las dos curvas de acierto.
¿Una pérdida menor siempre cambia el acierto? Compara la MLP con el modelo lineal en validación.
Tiempo: 15 minutos.

Elegir primero, probar después

- Elegir lineal o MLP por el acierto en validación.
- En empate, preferir el modelo sencillo.
- Fijar las decisiones antes de abrir prueba.
- Informar también límites de los datos y ejemplos de errores.

Matriz de confusión



Filas: clase real. Columnas: predicción. La diagonal recoge aciertos. Los valores fuera de ella muestran qué clases se confunden.

No resumir todo en un porcentaje

- Acierto global: predicciones correctas sobre el total.
- Precisión por clase: de las predicciones de esa clase, cuántas eran correctas.
- Recall por clase: de sus ejemplos reales, cuántos recuperamos.
- Support: cuántos ejemplos reales de esa clase se evaluaron.

Predice → ejecuta → modifica → explica

Cierra las decisiones y ejecuta la matriz. Describe dos errores.
Si no hay errores, explica dos límites del conjunto y usa la actividad 6 para estudiar fallos.
Tiempo: 12 minutos.

¿Qué ocurre si movemos la pieza?

- El modelo se entrenó con un rango limitado de posiciones.
- El diagnóstico desplaza las imágenes de prueba hacia abajo y derecha.
- No actualizamos pesos: observamos el efecto del cambio.
- No es una nueva prueba independiente; sigue usando las mismas piezas.

Predice → ejecuta → modifica → explica

Compara el acierto original y tras desplazar las imágenes. Observa también los posibles recortes.
¿Qué nuevos datos recogerías antes de desplegar?
Tiempo: 13 minutos.

Aumentar datos con criterio

- Transformaciones de entrenamiento pueden ampliar variaciones plausibles.
- La transformación debe conservar la etiqueta.
- Separar piezas originales antes de crear versiones aumentadas.
- No aumentar prueba para elegir el modelo ni confundir versiones con piezas nuevas.

De dibujos a fotografías reales

- Definir clases, condiciones de captura y unidad de separación.
- Revisar permisos, etiquetas, duplicados y equilibrio de clases.
- Incluir piezas nuevas y condiciones de uso en la evaluación.
- Comprobar rendimiento por clase y consecuencias de los errores.

Entrega y preguntas de cierre

- Particiones y comparación de modelos en validación.
- Curvas, matriz de confusión y dos errores o limitaciones.
- Explica por qué prueba no se usa para elegir hiperparámetros.
- Propón una evaluación con fotografías reales.

Lecturas para ampliar

- Bishop y Bishop. *Deep Learning: Foundations and Concepts*. Redes, entrenamiento y convolución.
- Szeliski. *Computer Vision: Algorithms and Applications*, 2.ª edición. Reconocimiento visual.
- Documentación de scikit-learn: separación por grupos, pipelines, MLP y métricas.

Figuras originales del curso. Resultados procedentes del notebook sintético.