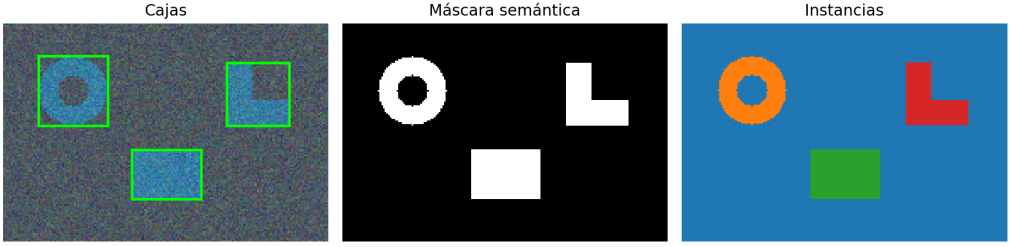
Localizar y delimitar piezas

Visión artificial para producto y fabricación aditiva

Fundamentos de la Inteligencia Artificial

Tema 3 · Sesión de 150 minutos

Una etiqueta ya no basta



¿Queremos saber qué aparece, dónde está o qué píxeles ocupa? La salida necesaria cambia el problema.

Objetivos

- Distinguir clasificación, detección y tipos de segmentación.
- Interpretar coordenadas, puntuaciones y máscaras.
- Ajustar reglas en validación y evaluar sin cambiarlas en prueba.
- Reconocer errores de localización, unión y omisión.

Ruta · 150 minutos

Bloque	Minutos
Salidas y anotaciones · actividad 1	20
Segmentación aprendida · actividad 2	25
Umbrales · actividad 3	20
Descanso	10
Cajas y evaluación · actividad 4	25
Instancias y contacto · actividad 5	20
Prueba y errores · actividad 6	20
Cierre	10

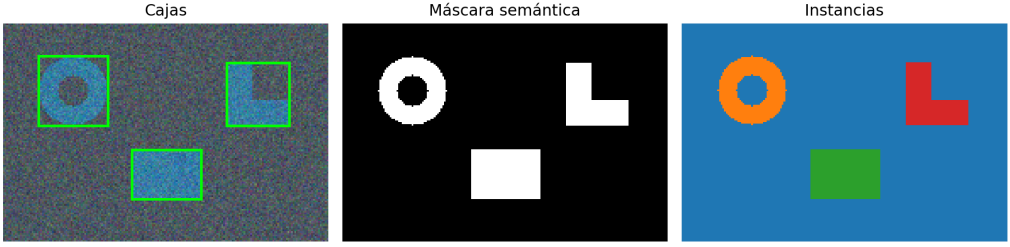
De clasificar a localizar

- Clasificación: una etiqueta para la imagen.
- Detección: cajas, clases y puntuaciones para los objetos.
- Segmentación semántica: una clase para cada píxel.
- Segmentación de instancias: una máscara separada para cada objeto.

Qué necesita un proyecto de producto

- Contar piezas sobre una bandeja: detectar y separar objetos.
- Medir superficie visible: delimitar con una máscara.
- Localizar una marca: caja o máscara según el detalle requerido.
- Medir dimensiones físicas requiere además escala y geometría de captura.

Las anotaciones son la referencia



En nuestros dibujos se conocen por construcción. En fotografías, las personas deben definir y revisar el criterio.

Semántica, instancias y panóptica

- Semántica: todas las piezas pueden compartir una misma etiqueta.
- Instancias: cada pieza recibe un identificador distinto.
- Panóptica: combina clases por píxel e identidades para objetos contables.
- No todas las tareas ni modelos producen las tres salidas.

Una convención para las cajas

Notebook

`(xmin, ymin, xmax, ymax)` con extremos finales excluidos.

- x corresponde a columnas; y corresponde a filas.
- Anchura = xmax - xmin; altura = ymax - ymin.
- Otros formatos usan centro, anchura y altura, o valores normalizados.
- Comprobar el formato antes de dibujar o comparar cajas.

Notebook · Actividad 1 · Leer las anotaciones

Predice → ejecuta → modifica → explica

Compara cajas, máscara semántica e identificadores.
¿Qué usarías para contar piezas? ¿Qué usarías para excluir el agujero de una arandela de su área?
Tiempo: 10 minutos.

La cadena que ejecutaremos

Práctica

RGB $\rightarrow$ modelo por píxel $\rightarrow$ puntuación $\rightarrow$ umbral $\rightarrow$ limpieza $\rightarrow$ componentes $\rightarrow$ cajas

- Modelo aprendido: regresión logística con tres entradas RGB.
- Agrupación geométrica: componentes conexas.
- Una sola clase de interés: pieza. Las formas no se clasifican.

Aprender píxel a píxel

- Cada píxel aporta tres números y una etiqueta pieza/fondo.
- El modelo aprende qué colores se asocian a pieza.
- No usa vecinos, contornos ni identidad de objetos.
- Separar escenas completas evita compartir píxeles de la misma imagen entre conjuntos.

Datos y separación

- Entrenamiento: 12 escenas; 1500 píxeles muestreados por escena.
- Validación: cuatro escenas para elegir el umbral.
- Prueba: seis escenas distintas con decisiones ya fijadas.
- Contacto y color nuevo: diagnósticos de fallo posteriores, sin reajuste.

El mapa de puntuaciones

- Una salida entre 0 y 1 por píxel.
- Todavía no es una máscara binaria ni una lista de objetos.
- La estimación depende de lo aprendido y de las condiciones.
- No interpretar la puntuación como certeza garantizada o universal.

Segmentación profunda: más contexto

- Un modelo convolucional puede combinar color y estructura local.
- Un codificador resume características; un decodificador recupera resolución.
- U-Net emplea conexiones entre escalas para recuperar detalle.
- Estos modelos requieren pesos y datos apropiados; no se ejecutan en esta práctica.

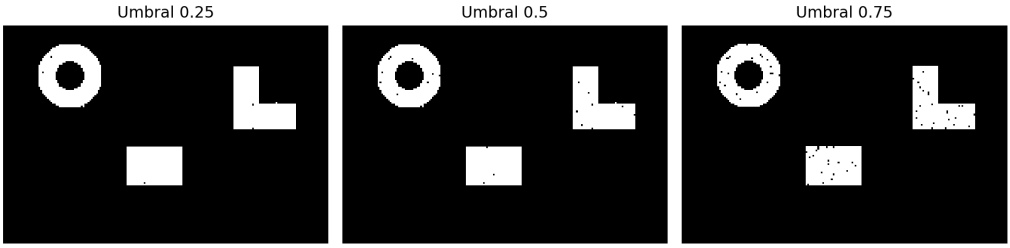
Predice → ejecuta → modifica → explica

Ejecuta el modelo y observa su mapa de puntuaciones.
¿Qué puede aprender usando solo RGB? ¿Qué ocurriría con una pieza de otro color?
Tiempo: 12 minutos.

Tres decisiones diferentes

- Umbral de puntuación: decide si un píxel es pieza.
- Área mínima: descarta regiones pequeñas tras segmentar.
- Umbral de IoU: decide si una caja coincide durante evaluación.
- No son intercambiables ni significan confianza en el mismo evento.

Cambiar el umbral



Comparar sobre validación. Un umbral más alto exige mayor puntuación, pero puede perder píxeles de pieza.

Limpiar también puede borrar información

- Eliminar regiones pequeñas puede reducir motas falsas.
- También puede eliminar piezas o marcas pequeñas reales.
- Rellenar agujeros no sería correcto para medir una arandela.
- Registrar qué operaciones se aplican y con qué escala de imagen.

Elegir sin consultar prueba

- Comparar IoU semántica media en las escenas de validación.
- Elegir un umbral antes de abrir prueba.
- El tamaño mínimo de 30 píxeles se fija de antemano.
- Si cambiamos las reglas tras analizar prueba, necesitamos otra evaluación independiente.

Notebook · Actividad 3 · Umbral y limpieza

Predice → ejecuta → modifica → explica

Compara tres umbrales y observa la eliminación de regiones pequeñas.
¿Puede una limpieza aparentemente útil borrar algo importante para el problema?
Tiempo: 13 minutos.

Descanso · 10 minutos

¿Una mancha conectada equivale siempre a una pieza?

Componentes conexas

- Agrupar píxeles que se tocan según una regla de vecindad.
- Hoy: conexiones por arriba, abajo, izquierda y derecha.
- Cada región produce una caja que encierra sus píxeles.
- Ni la conectividad ni la caja identifican por sí solas un objeto físico.

Detectores profundos: otra forma de obtener cajas

- Aprenden a proponer localizaciones y clases de objetos.
- Familias como YOLO predicen cajas y puntuaciones mediante una red.
- Otros enfoques usan propuestas de regiones o predicción de conjuntos.
- Las clases aprendidas deben corresponder a lo que buscamos.

Puntuaciones y cajas duplicadas

- Filtrar puntuaciones bajas limita las predicciones conservadas.
- Algunos detectores producen varias cajas del mismo objeto.
- NMS suprime candidatas muy solapadas según puntuación e IoU.
- No confundir duplicados con dos objetos reales cercanos. No aplicamos NMS en el notebook.

IoU: cuánto se solapan dos regiones

Intersección sobre unión

$$\mathrm{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

- 1: coincidencia completa. 0: sin intersección.
- Puede aplicarse a máscaras o a cajas, con significados geométricos distintos.
- En máscara vacía frente a vacía usamos 1 por convenio; no ocurre en estas escenas.

Ejemplo numérico de cajas

Dos cajas de 10×10 desplazadas 5 píxeles

Intersección: $5 \times 10 = 50$. Unión: $100 + 100 - 50 = 150$.

$$\mathrm{IoU} = 50/150 \approx 0{,}333$$

No superan un criterio de coincidencia con IoU mínima de 0,5.

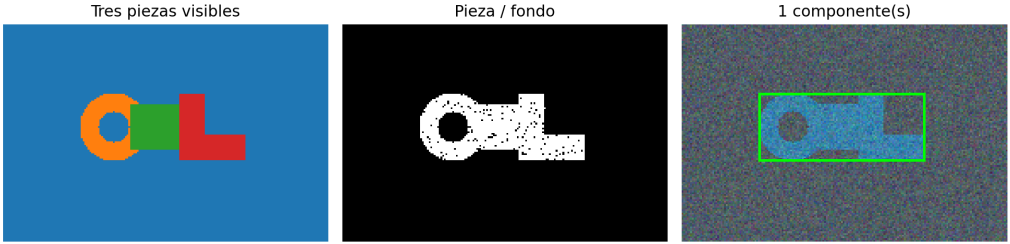
Una caja incluye fondo

- La caja rectangular puede contener agujeros y espacio vacío.
- IoU de cajas no mide exactamente el borde de la pieza.
- La máscara permite estimar área visible en píxeles.
- Para mm^2 necesitamos calibración y supuestos sobre plano y perspectiva.

Predice → ejecuta → modifica → explica

Genera cajas a partir de componentes y comprueba el cálculo de IoU.
¿Por qué una caja de arandela sobreestima su área visible de material?
Tiempo: 12 minutos.

Contacto: buena máscara, mal recuento



Las piezas se tocan y forman una región. La máscara semántica no contiene necesariamente la frontera entre instancias.

Segmentación de instancias

- Mask R-CNN combina localización y máscaras por objeto.
- Otras familias predicen máscaras e identidades mediante distintos mecanismos.
- Modelos guiados por puntos o cajas, como SAM, necesitan indicaciones.
- Una máscara guiada no aporta automáticamente una clase industrial correcta.

Qué se ve y qué queda oculto

- Nuestros identificadores describen la parte visible de cada pieza.
- Una caja de referencia encierra esa parte visible.
- Estimar la pieza completa tras una oclusión es otro problema.
- El criterio de anotación debe ser consistente con la evaluación.

Predice → ejecuta → modifica → explica

Observa la escena con contacto. Compara número real de piezas, número de componentes e IoU de máscara.
¿Por qué una métrica buena no responde a todas las preguntas?
Tiempo: 10 minutos.

Evaluar las cajas: emparejar sin duplicar

- Comparar cajas predichas con referencias de la misma escena.
- Cada referencia se empareja como máximo con una predicción.
- Coincidencia aceptada: verdadero positivo (TP).
- Predicción sin pareja: falso positivo (FP); referencia sin pareja: falso negativo (FN).

Precisión y recall de detección

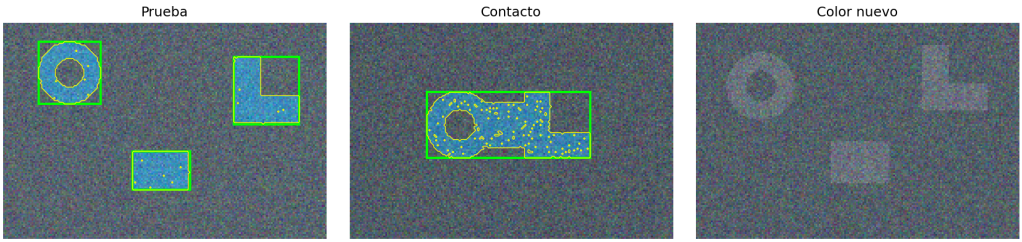
$$\text{Precisión} = \frac{TP}{TP + FP} \qquad \text{Recall} = \frac{TP}{TP + FN}$$

- Precisión: cuántas predicciones aceptadas correspondían a una referencia.
- Recall: cuántas referencias se recuperaron.
- Hay que indicar el umbral de IoU y el protocolo de emparejamiento.

El protocolo docente y sus límites

- Una clase; emparejamiento voraz de pares por IoU decreciente.
- Aceptamos pares con IoU de al menos 0,5.
- Calculamos precisión y recall en ese punto de operación.
- No es AP/mAP: esos protocolos incluyen otros detalles y ordenación por puntuación.

Prueba y diagnósticos de fallo



Verde: cajas obtenidas. Amarillo: contorno de máscara. Los diagnósticos no se usan para volver a elegir el umbral.

Predice → ejecuta → modifica → explica

Obtén métricas y las tres escenas anotadas. Describe dos fallos y su posible causa.
Descarga la figura antes de cerrar Colab.
Tiempo: 15 minutos.

Elegir la salida según la decisión

- Contar objetos: necesitamos separar instancias de forma fiable.
- Delimitar superficie: importa la calidad de la máscara.
- Inspeccionar marcas pequeñas: revisar resolución y eliminación por área.
- Medir físicamente: controlar captura, calibración y tolerancias.

Entrega y cierre

- Tres escenas anotadas y tabla de resultados.
- Dos errores explicados con sus condiciones.
- Distinguir umbral de puntuación, área e IoU de evaluación.
- Proponer datos nuevos para comprobar el sistema tras una mejora.

Lecturas para ampliar

- Szeliski. *Computer Vision: Algorithms and Applications*, 2.ª edición. Segmentación y reconocimiento.
- U-Net (Ronneberger et al., 2015); Mask R-CNN (He et al., 2017).
- Segment Anything (Kirillov et al., 2023).
- Documentación de scikit-image: etiquetado, regiones y morfología.

Figuras originales del curso, generadas con el notebook. Los modelos profundos se introducen de forma conceptual.