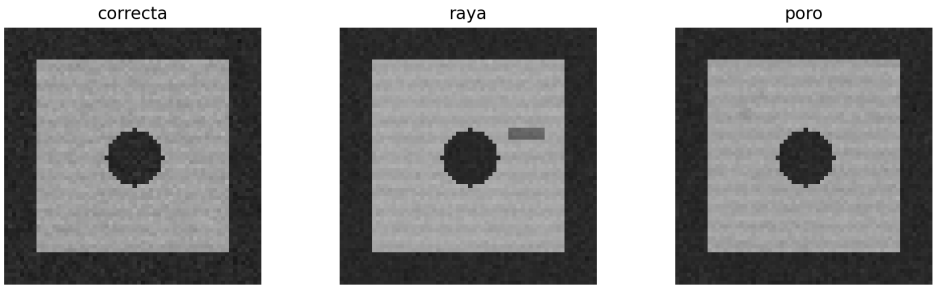
Inspección y detección de anomalías

Visión artificial para producto y fabricación aditiva

Fundamentos de la Inteligencia Artificial

Tema 4 · Sesión de 150 minutos

Aprender lo normal para buscar desviaciones



Si tenemos muchas piezas correctas y pocos defectos conocidos, ¿qué podemos aprender y qué queda sin garantizar?

Objetivos

- Distinguir anomalía visual y defecto según una especificación.
- Construir una referencia usando solo piezas correctas.
- Elegir un umbral con validación y justificar sus consecuencias.
- Analizar falsas alarmas, omisiones y cambios de captura.

Ruta · 150 minutos

Bloque	Minutos
Normalidad y datos · actividad 1	20
Referencia y puntuación · actividad 2	25
Umbral y decisiones · actividad 3	25
Descanso	10
Prueba y métricas · actividad 4	20
Mapas y errores · actividad 5	20
Cambios y frecuencia · actividad 6	20
Cierre	10

¿Qué queremos decidir?

- Aceptar, revisar o rechazar según un criterio de calidad definido.
- La salida del modelo es evidencia para esa decisión.
- Una marca visible puede ser admisible según tamaño y zona.
- Un defecto funcional puede no ser visible en una fotografía.

Anómalo no equivale a defectuoso

- Anómalo: se aparta de lo que representa nuestra referencia.
- Defectuoso: incumple una especificación.
- Una pieza correcta de otro color puede ser anómala.
- Un defecto repetido en el entrenamiento puede parecer normal.

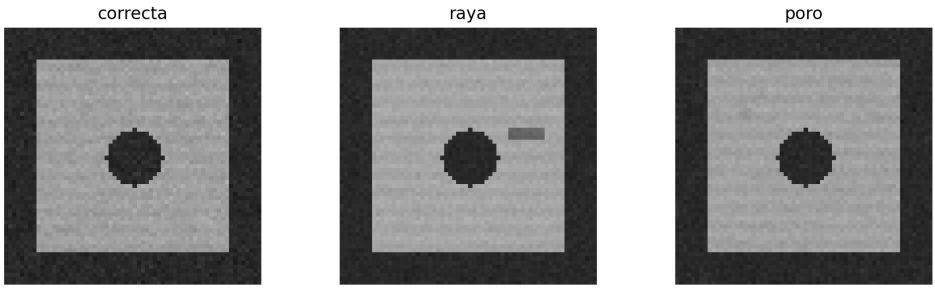
Tres enfoques de inspección

- Clasificación supervisada: aprender a distinguir clases con etiquetas.
- Anomalías: aprender una referencia de normalidad y puntuar desviaciones.
- Reglas y metrología: comprobar dimensiones o condiciones explícitas.
- El enfoque se elige por el problema, los datos y la decisión necesaria.

Normalidad bien definida

- Incluir variaciones admisibles de textura, iluminación y acabado.
- Excluir piezas incorrectas de la referencia normal.
- Definir regiones inspeccionables y condiciones de captura.
- Revisar la procedencia por pieza, lote y sesión de captura.

Datos del experimento



Superficies sintéticas alineadas, variación de brillo y textura, rayas y poros simulados. No son fotografías de defectos reales.

Separación y función de cada conjunto

- Entrenamiento: 60 imágenes correctas para aprender la referencia.
- Validación: 40 correctas y 40 con defectos para elegir el umbral.
- Prueba: 60 correctas y 60 con defectos, sin ajustar decisiones.
- Las escenas son independientes por semilla; comparten un generador limitado.

Notebook · Actividad 1 · Definir lo normal

Predice → ejecuta → modifica → explica

Explora correcta, raya y poro; localiza la zona de inspección.
¿Qué defectos no podríamos encontrar si están fuera de la región de interés?
Tiempo: 10 minutos.

Preparación de entrada

- ROI fija: interior de la superficie, sin borde ni agujero.
- Restar la mediana de la ROI reduce cambios globales de brillo.
- Aprender media y variación por posición solo en entrenamiento.
- Supuesto crítico: las posiciones corresponden a zonas comparables de piezas alineadas.

Una referencia estadística sencilla

En cada posición

$$z(i,j) = \frac{|x(i,j) - \mu(i,j)|}{\max(\sigma(i,j), \sigma_{\min})}$$

- Media y desviación se estiman con imágenes correctas preparadas.
- El mínimo de desviación evita divisiones por valores diminutos.
- La magnitud expresa alejamiento; no una probabilidad de defecto.

Del mapa a una puntuación por pieza

- Obtener desviaciones dentro de la ROI.
- Ordenar implícitamente sus valores y conservar el 1 % mayor.
- Promediar ese grupo para obtener una puntuación.
- El porcentaje y la preparación son decisiones del modelo que deben validarse.

Pequeño defecto, gran superficie

- Una media sobre toda la imagen puede diluir una marca pequeña.
- Una puntuación local concentra la atención en las desviaciones grandes.
- Un poro débil puede seguir mezclándose con la variación normal.
- Mayor puntuación no implica necesariamente mayor gravedad funcional.

Qué no aprende este modelo

- No usa características profundas ni relaciones complejas entre zonas.
- No identifica por sí mismo la causa física de una desviación.
- No establece tolerancias de fabricación.
- No se adapta automáticamente a piezas desalineadas o a productos nuevos.

Predice → ejecuta → modifica → explica

Ejecuta el modelo y compara mapas y puntuaciones.
¿Qué sucede al promediar todo el mapa en lugar de su parte más alta?
Tiempo: 12 minutos.

Familias de métodos para ampliar

- Distancias y densidades: comparar características con ejemplos normales.
- Autoencoders: aprender a reconstruir y estudiar diferencias.
- Características preentrenadas por regiones: referencias como PaDiM y PatchCore.
- Se introducen aquí conceptualmente; no se ejecutan en el notebook.

Reconstrucción: idea y límite

Esquema

Imagen $\rightarrow$ codificador $\rightarrow$ representación $\rightarrow$ decodificador $\rightarrow$ reconstrucción

- Se puede estudiar el error entre entrada y reconstrucción.
- Una mala reconstrucción no siempre significa defecto.
- Una red también puede reconstruir anomalías y ocultar su señal.

Características y vecinos normales

- Un extractor convierte regiones en vectores de características.
- Se compara cada región con una distribución o memoria de normalidad.
- La distancia puede transformarse en mapa y puntuación.
- El dominio del extractor, la resolución y los datos normales condicionan el resultado.

Una puntuación aún no es una decisión

Regla del notebook

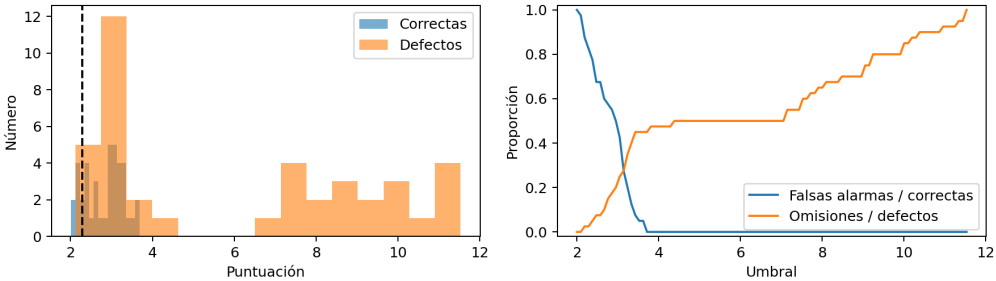
Alarma si puntuación $\geq$ umbral.

- Bajar el umbral aumenta o mantiene las alarmas.
- Subirlo reduce o mantiene las alarmas.
- El punto de operación expresa un compromiso que debe justificarse.

Dos errores con consecuencias diferentes

- FP: pieza correcta que genera una falsa alarma.
- FN: pieza defectuosa que no genera alarma.
- TP: defecto con alarma; TN: pieza correcta sin alarma.
- La clase positiva y la regla de referencia deben quedar explícitas.

Elegir con validación



Comparamos candidatos antes de abrir prueba. Las distribuciones pueden solaparse; ningún umbral tiene por qué separar todos los casos.

Penalizaciones hipotéticas

Dos criterios del ejercicio

$$L_1 = FP + 5FN \qquad L_2 = 5FP + FN$$

- El primero penaliza más las omisiones; el segundo, las falsas alarmas.
- Son unidades docentes hipotéticas, no costes industriales estimados.
- El equilibrio 50/50 de esta validación también influye en la elección.
- Si ningún umbral satisface el objetivo, hay que mejorar el sistema.

Si no tenemos defectos etiquetados

- Puede fijarse un umbral con una referencia de puntuaciones normales.
- Por ejemplo, un percentil de un conjunto de calibración separado.
- Eso describe alarmas sobre normales observados, no sensibilidad a defectos desconocidos.
- Se necesita evaluación con anomalías relevantes para conocer las omisiones.

Notebook · Actividad 3 · Justificar el umbral

Predice → ejecuta → modifica → explica

Compara los dos criterios de penalización sobre validación.
Justifica una decisión antes de abrir prueba. No cambies reglas consultando sus resultados.
Tiempo: 15 minutos.

Descanso · 10 minutos

¿Qué significa una tasa del 5 % de falsas alarmas?

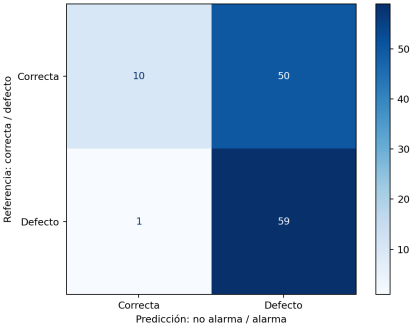
Los denominadores importan

$$\mathrm{FPR} = \frac{FP}{FP + TN} \qquad \mathrm{Recall} = \frac{TP}{TP + FN}$$

$$\text{Precisión} = \frac{TP}{TP + FP}$$

- FPR: proporción de correctas que generan alarma.
- Recall: proporción de defectos que generan alarma.
- Precisión: proporción de alarmas que eran defectos.

Abrir prueba una vez



Filas: referencia. Columnas: decisión. El umbral, la referencia y la puntuación ya se han fijado.

Informar por tipo de defecto

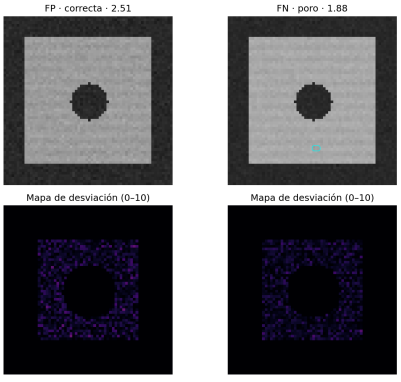
- El promedio puede ocultar que las rayas se detectan y los poros se omiten.
- Examinar resultados según tamaño, contraste, posición y tipo.
- Informar el número de ejemplos de cada categoría.
- Cero errores en pocos casos no demuestra una tasa real de cero.

Notebook · Actividad 4 · Evaluar sin reajustar

Predice → ejecuta → modifica → explica

Obtén la matriz y las tasas. Compara rayas y poros.
¿FPR y porcentaje de alarmas incorrectas tienen el mismo denominador?
Tiempo: 12 minutos.

Analizar casos concretos



Arriba: imagen y referencia sintética en cian cuando hay defecto. Abajo: desviación, con escala compartida de 0 a 10.

Mapa de anomalía no es máscara validada

- Un valor alto indica alejamiento respecto al modelo de referencia.
- No confirma material defectuoso ni delimita su contorno exacto.
- Para evaluar localización necesitamos anotaciones y métricas espaciales.
- Hoy evaluamos la alarma por imagen, no segmentación de defectos.

Convertir el error en una hipótesis

- Omisión: ¿marca demasiado pequeña o poco contrastada?
- Falsa alarma: ¿variación admisible o captura fuera de condiciones?
- Proponer cambios de adquisición, datos, preparación o puntuación.
- Desarrollar con entrenamiento/validación y comprobar con nueva prueba.

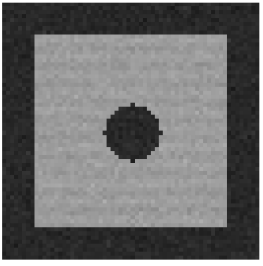
Notebook · Actividad 5 · Examinar fallos

Predice → ejecuta → modifica → explica

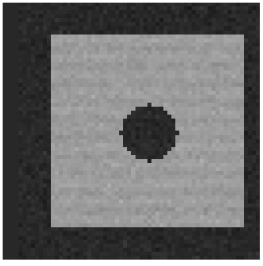
Revisa una falsa alarma y una omisión si existen. Si falta una categoría, decláralo.
Distingue mapa de desviación y contorno de referencia.
Tiempo: 10 minutos.

Un cambio de captura puede parecer defecto

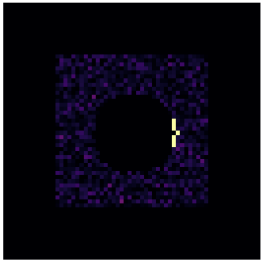
Correcta original



Correcta desplazada



Desviación sin realinear



La pieza sigue siendo correcta. El modelo compara posiciones que ya no corresponden a las mismas zonas.

Vigilar cambios durante el uso

- Revisar enfoque, luz, posición, cámara, material y acabado.
- Registrar resultados por lote y condiciones de captura.
- Investigar aumentos de alarmas antes de incorporar datos a la referencia.
- No asumir que cada ejemplo nuevo es correcto por proceder de producción.

Defectos raros: un ejemplo aritmético

Supuestos hipotéticos

10 000 piezas, 1 % defectuosas, recall 90 % y FPR 5 %.

- 100 defectos: 90 alarmas correctas y 10 omisiones.
- 9900 correctas: 495 falsas alarmas.
- De 585 alarmas, 90 son defectos: precisión aproximada del 15,4 %.
- No son tasas estimadas para una fábrica ni una extrapolación del notebook.

Evaluación equilibrada frente a frecuencia de uso

- Un conjunto equilibrado facilita comparar tipos y examinar errores.
- La proporción de alarmas correctas depende también de la frecuencia de defectos.
- Recall y FPR pueden cambiar si cambian las condiciones, no solo la frecuencia.
- Informar el reparto de datos y evitar trasladar un porcentaje sin contexto.

Predice → ejecuta → modifica → explica

Compara alarmas antes y después del desplazamiento. Revisa el ejemplo de defectos raros.
¿Por qué 90 % de recall no implica que el 90 % de alarmas sean correctas?
Tiempo: 13 minutos.

Entrega y cierre

- Tabla de criterios y justificación del umbral.
- Matriz de prueba, tasas y resultados por tipo de defecto.
- Dos casos comentados o ausencia explícita de esa categoría.
- Diagnóstico de desplazamiento y propuesta de evaluación futura.

Lecturas para ampliar

- Szeliski. *Computer Vision: Algorithms and Applications*, 2.ª edición. Bases de visión y reconocimiento.
- Bergmann et al. (2019). MVTec AD: referencia de evaluación de anomalías industriales.
- Defard et al. (2021). PaDiM. Roth et al. (2022). PatchCore.
- Documentación de scikit-learn: matriz de confusión y métricas de clasificación.

Figuras originales del curso, generadas con el notebook sintético.