Relacionar texto e imagen

Visión artificial para producto y fabricación aditiva

Fundamentos de la Inteligencia Artificial

Tema 5 · Sesión de 150 minutos

Dos preguntas nuevas

- ¿Puedo encontrar una imagen describiendo lo que busco?
- ¿Puedo explorar una idea de producto mediante texto?
- ¿Qué evidencia me permite aceptar el resultado?



Objetivos

- Entender representaciones compartidas de imagen y texto.
- Comparar búsqueda, clasificación sin ajuste y generación.
- Interpretar similitud sin confundirla con certeza.
- Revisar conceptos visuales con requisitos y límites explícitos.

Ruta · 150 minutos

Bloque	Minutos
Catálogo y representaciones · actividad 1	20
Búsqueda · actividad 2	20
Candidatas y pesos · actividad 3	20
Lenguaje y límites · actividad 4	20
Descanso	10
Generación y ruido · actividad 5	25
Revisión de conceptos · actividad 6	25
Cierre	10

Tres tareas que conviene distinguir

- Recuperación: ordenar imágenes existentes según una consulta.
- Clasificación sin ajuste: comparar una imagen con descripciones candidatas.
- Generación: producir una nueva imagen condicionada por instrucciones.
- Un modelo de lenguaje con visión puede además redactar respuestas sobre una imagen.

Multimodal: relacionar tipos de datos

- Texto e imagen tienen representaciones de entrada diferentes.
- Los modelos aprenden relaciones a partir de sus datos y objetivos.
- Relacionar apariencia y descripción no equivale a verificar una pieza.
- La salida depende de qué tarea se entrenó a resolver.

El catálogo del curso



Seis ilustraciones procedimentales y dos conceptos generados. No hay taza verde ni dos tazas azules en una misma imagen.

Qué ejecutaremos de verdad

- Similitudes con vectores reales de CLIP guardados previamente.
- Clasificación mediante descripciones y examen de sus fallos.
- Un proceso directo de añadir ruido; no un generador aprendido.
- Revisión de dos renders generados previamente y sus instrucciones.

Por qué guardamos vectores

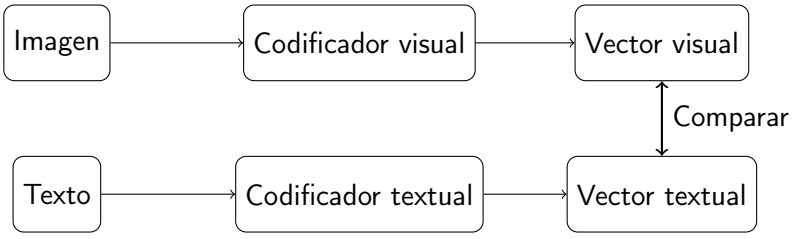
- Evitar que cada alumno descargue cientos de MB para la ruta principal.
- Conservar modelo, revisión, procesador y huellas de las imágenes.
- Permitir recalcular rankings con las consultas incluidas.
- El notebook opcional ejecuta CLIP para frases nuevas. No sustituimos sus vectores por números inventados.

Notebook · Actividad 1 · Leer el catálogo

Predice → ejecuta → modifica → explica

Explora las imágenes y las consultas disponibles.
¿Qué debería pasar si buscas algo ausente? ¿Un ranking puede devolver siempre un primer resultado?
Tiempo: 10 minutos.

Dos codificadores, un espacio común



Aprendizaje contrastivo: una intuición

- Usar pares de imágenes y textos asociados durante preentrenamiento.
- Favorecer similitud de pares asociados frente a otras combinaciones.
- Aprender características reutilizables para nuevas consultas.
- El texto de origen puede ser incompleto, ambiguo o contener sesgos.

CLIP del notebook

- Variante ViT-B/32: codificador visual transformer y codificador textual.
- Vectores de 512 componentes normalizados para comparar.
- Usamos pesos preentrenados; no entrenamos durante la sesión.
- La tarjeta del modelo delimita sus usos y limitaciones; no es una certificación de aplicación industrial.

Similitud coseno

Comparar direcciones

$$s(u, v) = \frac{u \cdot v}{\|u\| \, \|v\|}$$

- Para vectores normalizados basta el producto escalar.
- Mayor valor indica mayor alineación según esa representación.
- No expresa porcentaje de exactitud, seguridad ni viabilidad técnica.

Buscar es ordenar un catálogo

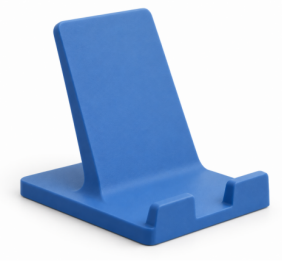
taza_azul · 0.343



taza_roja · 0.299



concepto_B · 0.245



Consulta: «a drawing of a blue mug». El mejor resultado se elige entre las imágenes disponibles, aunque ninguna cumpla literalmente otra consulta.

Antes de interpretar el ranking

- Revisar qué elementos existen en el catálogo.
- Comprobar idioma, tipo de imagen y recorte de entrada.
- Inspeccionar varios resultados y registrar fallos concretos.
- Definir consultas y relevancia antes de estimar rendimiento en una colección real.

Notebook · Actividad 2 · Buscar con texto

Predice → ejecuta → modifica → explica

Cambia entre las consultas de lámpara, arandela y soporte.
Registra una predicción y el resultado. No interpretes el coseno como probabilidad.
Tiempo: 12 minutos.

Clasificar sin entrenar una cabeza nueva

- Describir las clases candidatas mediante texto.
- Comparar cada descripción con el vector de la imagen.
- Seleccionar la mayor similitud entre esas candidatas.
- Sin ajuste para esta tarea no significa sin entrenamiento previo.

Softmax: repartir peso entre candidatas

Pesos relativos

$$p_k = \frac{\exp(\ell_k)}{\sum_j \exp(\ell_j)}$$

- Los logits son similitudes escaladas por el modelo.
- Los pesos suman uno dentro del conjunto de opciones elegido.
- Si retiramos la respuesta adecuada, todavía suman uno.
- Esto no obliga a que ninguna opción sea correcta.

Un ejemplo de opciones incompletas

- Imagen: taza azul. Opciones: taza roja y taza verde.
- El modelo puede dar mucho peso a una de ellas.
- Añadir o quitar candidatas cambia los pesos normalizados.
- El coseno con cada frase existente no cambia al retirar otra frase.

Notebook · Actividad 3 · Cambiar candidatas

Predice → ejecuta → modifica → explica

Compara la clasificación con y sin la descripción de taza azul.
¿Qué cambia al retirar una opción? ¿Por qué la suma de pesos no demuestra acierto?
Tiempo: 12 minutos.

El lenguaje también es una variable

- Foto, dibujo y render pueden activar asociaciones distintas.
- Cambiar sustantivo, estilo o contexto puede modificar el ranking.
- Este modelo se usa principalmente con inglés según su tarjeta.
- Un acierto puntual en castellano no valida su comportamiento multilingüe.

Negación, cantidad y propiedades finas

- «Sin asa» no garantiza descartar todas las tazas con asa.
- «Dos tazas» requiere contar, no solo reconocer una taza.
- Un color ausente puede recuperar un objeto parecido de otro color.
- Evaluar cada requisito por separado cuando sea decisivo.

Responder sobre una imagen: otro tipo de modelo

- Un modelo de lenguaje con visión puede describir, comparar o responder preguntas.
- Su respuesta puede incluir inferencias que no se ven en la imagen.
- Pedir evidencia visible y separar observación de suposición.
- No ejecutamos un modelo conversacional visual en este notebook.

Notebook · Actividad 4 · Poner a prueba la interpretación

Predice → ejecuta → modifica → explica

Compara idioma, color ausente, negación y cantidad.
Documenta dos fallos y una forma específica de verificarlos.
Tiempo: 12 minutos.

Descanso · 10 minutos

Encontrar una imagen y generar una imagen son procesos distintos.

Generación condicionada

- Una instrucción orienta qué resultado se busca producir.
- La salida combina patrones aprendidos, condicionamiento y muestreo.
- Los requisitos geométricos pueden incumplirse aunque el render sea convincente.
- No todos los servicios generativos exponen modelo, semilla o parámetros.

Difusión: aprender un proceso inverso

Durante entrenamiento

Imagen con ruido + nivel de ruido $\rightarrow$ modelo $\rightarrow$ estimación para retirar ruido

Durante muestreo

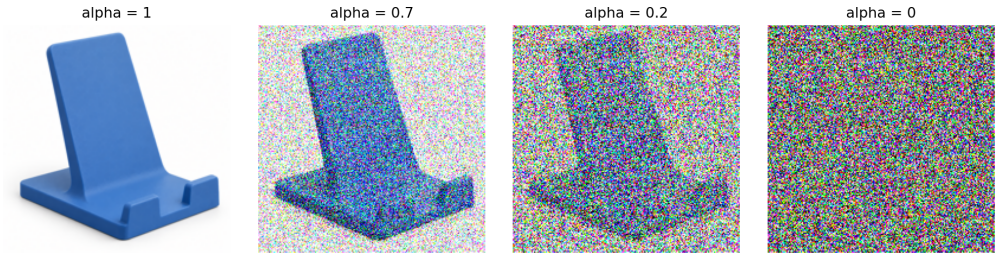
Estado ruidoso $\rightarrow$ pasos guiados por el modelo y el condicionamiento $\rightarrow$ imagen

No confundas el ejemplo directo del notebook con el proceso inverso aprendido.

Difusión latente

- Un codificador comprime la imagen a una representación latente.
- El proceso generativo opera en ese espacio en lugar de todos los píxeles.
- Un decodificador transforma el resultado latente en imagen.
- Es una familia de métodos; no atribuimos esta arquitectura al servicio que produjo nuestros dos conceptos.

El experimento directo del notebook



$$x_t = \sqrt{\alpha}\, x_0 + \sqrt{1-\alpha}\, \epsilon$$

Conocemos la imagen original y añadimos ruido. No aprendemos a crear una imagen nueva.

Semilla, pasos y condicionamiento

- La semilla inicializa una fuente de aleatoriedad cuando el sistema la expone.
- El resultado también depende de pesos, código, muestreador y entorno.
- Más pasos o más fuerza de texto no garantizan un resultado mejor.
- Cambiar la semilla de nuestro ejemplo solo cambia el ruido simulado.

Notebook · Actividad 5 · Añadir ruido

Predice → ejecuta → modifica → explica

Cambia la semilla y compara los extremos de alpha.
¿Por qué conocer la imagen original no resuelve el problema de generar una nueva?
Tiempo: 12 minutos.

Escribir un encargo de producto

- Definir función y contexto de uso.
- Separar requisitos visibles de requisitos que necesitan dimensiones o ensayos.
- Pedir vista, fondo y estilo que ayuden a comparar propuestas.
- Registrar instrucciones, parámetros disponibles y resultados seleccionados.

Dos conceptos, dos instrucciones



A · Encargo abierto



B · Restricciones visuales

Dos generaciones independientes sin semilla controlada; no son un experimento causal del efecto del prompt.

Qué añadió el encargo B

- Cuerpo continuo y base rectangular amplia.
- Respaldo plano y dos apoyos frontales con hueco central.
- Evitar miembros muy finos y perforaciones decorativas.
- Material azul mate, fondo neutro y ausencia de texto o cotas.

Observar, comprobar o dejar pendiente

- Visible: número aparente de apoyos y forma general.
- Por comprobar en CAD: conectividad, dimensiones y espesores.
- Por comprobar con proceso: orientación, soportes y tolerancias.
- Por comprobar funcionalmente: ajuste, estabilidad y resistencia.

Editar una imagen tampoco verifica geometría

- Texto, máscara o imagen de referencia pueden guiar una modificación.
- Elementos fuera de la zona buscada también pueden cambiar.
- Comparar invariantes antes y después: apoyos, huecos, proporciones.
- No ejecutamos edición ni generación en vivo como requisito de la práctica.

Del concepto al producto

Secuencia de trabajo

Encargo → variantes visuales → selección razonada → CAD → preparación de fabricación → prototipo → verificación

- La imagen ayuda a explorar y comunicar.
- Las decisiones técnicas necesitan evidencia adicional.

Una comparación más informativa

- Fijar modelo y parámetros disponibles.
- Variar una familia de requisitos cada vez.
- Generar varias muestras por condición y registrar los descartes.
- Evaluar con una rúbrica común; no seleccionar solo la imagen más atractiva.

Notebook · Actividad 6 · Revisar y reformular

Predice → ejecuta → modifica → explica

Compara los prompts completos y las dos imágenes. Completa la tabla de requisitos y escribe un encargo revisado.
Mantén «No verificable» cuando falte evidencia.
Tiempo: 14 minutos.

Entrega y cierre

- Tres búsquedas con predicción y resultado.
- Dos fallos de interpretación literal.
- Explicación de qué muestra y qué no muestra el ruido.
- Tabla de revisión y prompt mejorado con propuesta de comparación.

Fuentes y procedencia

- CLIP: tarjeta del modelo y documentación de Transformers.
- Radford et al. (2021). Learning Transferable Visual Models From Natural Language Supervision.
- Rombach et al. (2022). High-Resolution Image Synthesis with Latent Diffusion Models.
- Procedencia de vectores, revisiones y huellas: `procedencia_clip.json`.
- Instrucciones de generación: `prompts_generacion.json`.

Figuras originales del curso. Conceptos A y B creados con image_gen; modelo y semilla no expuestos por la herramienta.